Datathon 2026 – Round 1: EDA & Sales Forecasting for Vietnamese Fashion E-commerce

Trần Nam Anh Đặng Minh Phát Nguyễn Đức Hải
Ngô Thị Ánh Dương
Team: The Richers
Datathon 2026 – Round 1 Submission

Abstract

Báo cáo EDA và dự báo doanh thu cho e-commerce thời trang Việt Nam giai đoạn 2012–2022, được tổ chức theo **4 cấp độ Descriptive–Diagnostic–Predictive–Prescriptive**. EDA phát hiện: (i) Streetwear chiếm 75% portfolio (12.15 tỷ) với concentration risk; (ii) wrong_size là root cause 35% returns đồng nhất across category; (iii) COD cancel rate 16% gấp 2× online; (iv) tất cả mega sales VN (12.12, Black Friday, 11.11, Tết) đều *giảm* doanh thu 27–49%; (v) RFM phân 6 segment, Champions 24% population đóng góp 9.0 tỷ; (vi) Risk Tier classification flag 30 SKUs High Risk (median return 24%) cần can thiệp Q1 2023. Forecasting đề xuất **Hybrid Multi-Layer** với cross-table features, macro-event encoding và alpha-shrinkage residual stacking; CV Revenue R^2=0.7823, COGS R^2=0.7916 trên 2 fold time-series 2021–2022. Top-5 actionable recommendations với expected impact ∼1.7–1.8 tỷ tăng doanh thu và ∼500 triệu tiết kiệm chi phí/năm.

1 Exploratory Data Analysis

EDA phân tích 13 bảng (715K orderlines, 647K orders, 87,839 customers, 2,412 SP) qua **4 cấp độ Descriptive–Diagnostic–Predictive–Prescriptive** trên 3 chủ đề: Product Portfolio, Customer, Promotion/Operations. Dựa trên 5 Data Marts với metric chuẩn hóa (Net Revenue, Gross Margin, Return Rate qty-based).

1.1 Descriptive: Portfolio & Customer Snapshot

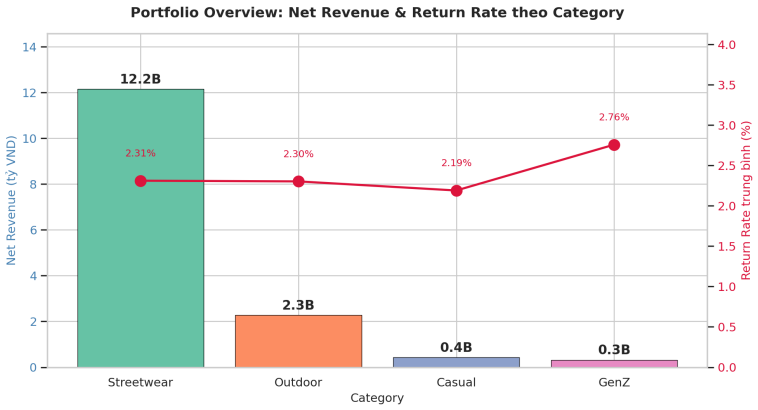

Figure 1: Doanh thu thuần và return rate theo Category. Streetwear 75% portfolio (12.15 tỷ VND), gấp 5.3× Outdoor; return rate đồng đều 2.2–2.8% across 4 category → vấn đề hệ thống.

Concentration risk lớn: Streetwear 75% revenue (12.15 tỷ); Outdoor 2.27 tỷ với 743 SKUs nhưng under-leveraged. Return rate đồng đều 2.2–2.8% across 4 category → **vấn đề hệ thống, không**

category-specific. GenZ (148 SKUs) outlier âm: return cao nhất 2.8%, margin thấp nhất 24.1% → product-market mismatch. **Customer base**: 87,839 khách, top segment 25–34 tuổi chiếm 28.4% revenue (Female 14.4%, Male 14.0%); Female nhỉnh hơn Male ở mọi nhóm tuổi — target cho size table fix (§1.2). 18–24 (sinh viên, 6.6%) là tier tiềm năng nhưng chưa convert hiệu quả.

1.2 Diagnostic: Wrong Size, COD, & Mega Sales Failure

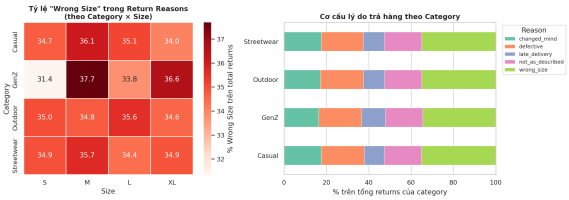

(a) Return reasons by Category × Size: wrong_size 35% root cause, đồng nhất 4 category.

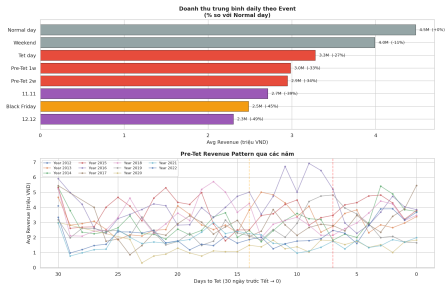

(b) Doanh thu daily theo events: tất cả mega sales VN đều giảm 27–49% so với normal day 4.48M.

Figure 2: Diagnostic findings: (a) wrong_size là root cause hệ thống của returns; (b) mega sales counter-intuitive — doanh thu **giảm** 27–49% trên mọi event.

Wrong_size = root cause hệ thống: 35% returns do size sai, đồng nhất across mọi category → **bảng quy đổi size + lack of UX guidance**, không phải chất lượng SP. Defective 20% + Not_as_described 18% + wrong_size => 70% root cause. Casual S/M hotspot (157, 145 returns). **COD = bom hủy đơn**: cancel rate 16% gấp 2× online (4 phương thức online identical 7.89–8.06%) → gap 8pp là vấn đề **commitment, không UX**. Cost ngầm: 15,468 đơn × 50–100K = **750 triệu – 1.5 tỷ VND/năm**. **Mega sales phản tác dụng**: 12.12 (−49%), Black Friday (−45%), 11.11 (−39%), Pre-Tết 2 tuần (−34%), Tết (−27%). Hypotheses: (1) **Pre-shopping** — khách biết lịch, mua đón đầu/cắt chờ; (2) **Discount cannibalization** — discount sâu kéo gross revenue xuống, đơn không tăng đủ; (3) **Operational saturation** — sàn quá tải → bỏ giỏ. Cross-ref correlation matrix: `Total_Discount_Amount` có $r = 0.76$ ($p < 0.001$) với `Returns_Changed_Mind` → discount sâu kích hoạt impulse + đổi ý.

1.3 Predictive: RFM Segmentation & Refund Cash-Flow Forecast

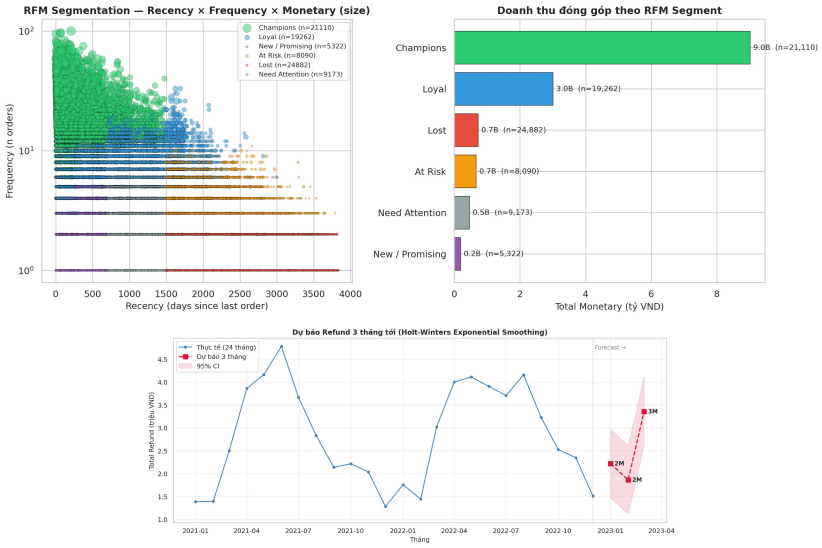

Figure 3: Predictive analytics: (top) RFM 6 segments — Champions 21K (9.0 tỷ), Loyal 19K (3.0 tỷ) là 2 nhóm cốt lõi; At Risk 8K (recency 2,028 ngày) cần win-back. (bottom) Holt-Winters forecast refund 3 tháng tới Q1 2023 với CI 95%, signal seasonality + trend phục hồi sau dip Q4 2022.

RFM Segmentation (Cell B.3.1): **Champions** 21,110 khách (24%) đóng góp **9.0 tỷ** revenue, monetary trung bình 427K — backbone retention. **Loyal** 19,262 khách (3.0 tỷ) feeder upgrade Champions. **At Risk** 8,090 khách (recency 2,028 ngày, monetary 661M) win-back high ROI. **Lost** 24,882 (recency >2,500 ngày) đã churn. New/Promising 5,322 cần convert trước window 90 ngày. **Risk Tier Classification** (Cell A.3.1): Low 1,355 SKUs (median return 3%), Medium 213 (6%), **High Risk chỉ 30 SKUs** nhưng median return **24%** — ưu tiên QC audit ngay trước Tết. **Refund Forecast** (Holt-Winters Exponential Smoothing 24-tháng): predict 3 tháng Q1 2023 với CI 95%. Pattern phát hiện: refund seasonal (peak Q2 2021 và Q2–Q3 2022 đều ∼4M triệu VND), trough cuối năm. Forecast cho thấy Q1 2023 refund sẽ **phục hồi từ dip Q4 2022** (∼1.5M) lên ∼2–3M, tiếp nối seasonal cycle. Combo với Risk Tier: **30 High Risk SKUs là driver chính** của refund spike — cắt return của nhóm này trước Tết để giảm refund peak Q1.

1.4 Prescriptive: Action Portfolio + Top 5 Concrete Actions

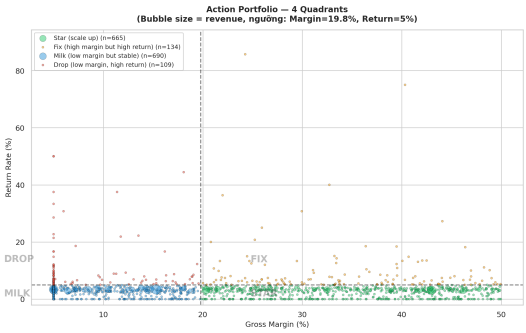

Figure 4: Action Portfolio Quadrant 1,598 SKUs (Margin 19.8%, Return 5%): Star 665, Milk 690, Fix 134, Drop 109.

SKU Quadrant: Star 665 (41.6%) backbone Streetwear — protect+scale; Milk 690 (43.2%) bundle với Star tăng AOV; Fix 134 (8.4%) Streetwear premium bị wrong_size returns → margin tiềm năng nếu fix size; Drop 109 (6.8%) đốt tiền kép ∼700 triệu refund/năm. **Channel Quality** (% Champions+% Loyal): organic_search 86.4 (3.93 tỷ rev), paid_search 73.7, social_media 72.0, email 48.6, direct 38.5, referral 35.4 → **gap 51pp**. Search-based thắng vì intent-driven traffic, direct/referral incidental. **Top 5 Actions 2023** (impact: $+1.7$–1.8 tỷ revenue, -500 triệu cost): **(1) Portfolio cleanup** — Drop 109 SKUs liquidation 30 ngày, Fix 134 SKUs 60-day rescue (giải phóng 700 triệu refund); **(2) AI size recommender** ưu tiên Casual S/M (30 triệu logistics + uy tín); **(3) COD verification** SMS/IVR $>$ 500K VND + discount prepaid 2–3% (250–500 triệu/năm); **(4) Marketing reallocation** $+30$–40% organic/paid_search, -30% direct/referral; tăng %Champions 24% → 28% ($+3,500 \times 427\text{K} = +1.5$ tỷ); **(5) Promo calendar 2023** — stop 12.12, cắt 80% Black Friday, Tết chỉ 3–4 ngày, A/B test 11.11 với 50% intensity (tiết kiệm 60–70% promo budget). **Risk Tier guard**: 30 High Risk SKUs (§1.3) cần QC audit 100% trước Tết để cắt refund peak Q1 (theo seasonal forecast).

2 Sales Forecasting (Phần 3)

2.1 Pipeline kiến trúc Hybrid Multi-Layer

Dự báo Revenue và COGS theo ngày cho 2023-01-01 đến 2024-07-01 (548 ngày), train trên 2012-07-04 đến 2022-12-31 (3,287 ngày). Đánh giá MAE, RMSE, R^2. Đề xuất kiến trúc 4 lớp:

1. **Baseline**: $\hat{y}_t = \mu_{base} \cdot g^{\Delta y} \cdot s_{m,d}$ với g geometric mean growth, $s_{m,d}$ seasonal index theo (month, day).
2. **Cross-table features**: 23 daily share ratios từ 4 dim tables (region/payment/device/source/status); test không có dim data → impute (month, dow) lookup từ train post-2020.
3. **Macro events**: 5 cờ regime (growth_era, 2019_slowdown, covid_lockdown, post_lockdown_recovery, inflation_2022) — chỉ áp COGS theo ablation.
4. **Alpha-shrinkage**: $\hat{y}_{final} = \hat{y}_{baseline} + \alpha \cdot \hat{r}_{ML}$, $\alpha < 1$ chống overfit (Stein-like). ML residual: XGBoost cho Revenue, CatBoost cho COGS theo per-target CV.

2.2 Cross-Validation đúng chiều thời gian & Ablation

CV time-series 2 fold rolling-origin (train $\leq$ 2020, val=2021; train $\leq$ 2021, val=2022; bỏ COVID 2020 outlier). **No leakage**: baseline được fit lại từ đầu cho mỗi fold với upper_year $= y - 1$, dim features impute từ post-2020 train data. Tối ưu α qua *combined score* $= \frac{\Delta MAE}{MAE_b} + \frac{\Delta RMSE}{RMSE_b} + (R^2 - R_b^2)$. Kết quả: $\alpha_{rev} = 0.350$, $\alpha_{cogs} = 0.275$.

Table 1: Ablation study CV (2 folds 2021+2022).

Approach	Rev MAE	Rev R^2	COGS MAE	COGS R^2
Original notebook (rank 1902)	583K	0.7587	544K	0.7194
Baseline only	597K	0.7663	489K	0.7821
Baseline + Alpha-shrinkage	569K	0.7773	476K	0.7871
+ Cross-table features (Plan A)	564K	0.7823	476K	0.7878
+ Macro events (COGS only)	**564K**	**0.7823**	**471K**	**0.7916**

2.3 SHAP, Compliance & Reproducibility

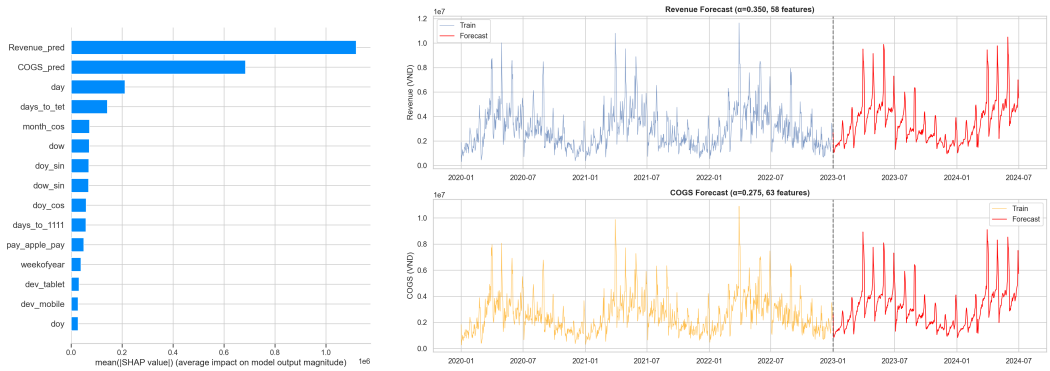

(a) SHAP Revenue residual (XGBoost, fold val=2022).

(b) Forecast Revenue/COGS 2023-01 đến 2024-07 (đỏ) kế thừa seasonal từ historical (xám).

Figure 5: (a) Feature importance cho Revenue residual; (b) Forecast 548 ngày, predictions ổn định.

Top-5 SHAP Revenue (XGB): `Revenue_pred` (1.12M), `COGS_pred` (684K), `day` (211K), `days_to_tet` (142K), `month_cos` (72K). **Top-5 SHAP COGS** (CatBoost): `COGS_pred` (1.01M), `Revenue_pred` (573K), `day` (157K), `is_growth_era` (153K), `is_2019_slowdown` (122K). Baseline dominate $\rightarrow$ ML học residual; `day`+`days_to_tet` là signal phi-tuyến (payday+Tết); macro events top-5 COGS confirms ablation $\rightarrow$ COGS nhạy cảm regime kinh tế. **Compliance 3 ràng buộc**: (i) `FEATS_REV`/`FEATS_COG` không chứa Revenue/COGS (mart4 test=NaN). (ii) Chỉ load file provided; macro flags là date-based encoding. (iii) seed=42, deterministic folds, notebook `04_MLE_KILLER_FINAL.ipynb`. **Code & Reproducibility**: GitHub repo `https://github.com/LineLuLan/The-Richers` (notebooks, mart-builders, submission).